

Prueba técnica — Data / Analytics Engineer @ Nébula

En Nébula estamos construyendo nuestro Data Lake corporativo desde cero. Esta prueba busca ver **cómo piensas y cómo decides**, no que la completes al 100%. **No dediques más de medio día**; valoramos criterio, arquitectura y comunicación por encima de la exhaustividad.

Contexto

Nébula es una insurtech que compara y contrata seguros y servicios del hogar. Captamos *leads* y los gestionamos con un call center. Los datos viven en un CRM (PostgreSQL) y queremos llevarlos a un data lake en AWS para tener métricas fiables y, más adelante, automatización e IA.

Te damos una muestra en `datos/` (CSV): `lead`, `llamada`, `persona`, `usuario`. **Son datos de producción: vienen sucios y con ruido**. Parte del ejercicio es que **decidas qué es válido y lo justifiques**. Las fechas y timestamps de los datos están en **UTC**.

Definiciones de negocio que necesitas: - Una **venta** = un lead cuyo estado es "Contratado". - Una **llamada efectiva** = duración mayor de 5 segundos.

Parte 1 — Construir (obligatoria)

Con la herramienta que prefieras (**dbt + SQL** es lo que usamos; vale SQL puro o Python), calcula:

1. **Leads por día**.
2. **Tasa de conversión** (ventas / leads).
3. **Llamadas efectivas por día y por agente**.

Incluye alguna **validación/test** y un **README** con tus decisiones y supuestos: qué consideraste válido, qué descartaste y **por qué confías en las cifras**.

Parte 2 — Diseñar (lo importante: cuéntanoslo, no hay que implementarlo)

Aquí queremos ver tu criterio de arquitectura. Sé concreto pero breve:

1. **Infraestructura (IaC)**: ¿cómo desplegarías la base en **AWS con Terraform** (almacenamiento, catálogo, motor de consulta)? ¿Qué servicios y por qué?
2. **Ingesta (CDC)**: ¿cómo llevarías `lead / llamada` desde PostgreSQL al lake **casi en tiempo real**, organizándolo en capas **Raw** → **Clean** → **Marts**? Trade-offs (CDC vs cargas completas, formato de tabla, upserts).
3. **Multi-fuente**: si mañana llega una **segunda fuente** distinta (p. ej. eventos de un proveedor cloud o ficheros en S3), ¿cómo la integrarías y la cruzarías con lo anterior?
4. **Gobierno y confianza**: si tus cifras no coincidieran con las que ve la aplicación, ¿a qué podría deberse y **cómo garantizarías que cuadran** (tests, reconciliación) y el control de acceso al dato?
5. **Histórico**: ¿cómo modelarías el **histórico de estados** de un contrato para responder "¿en qué estado estaba el 1 de marzo?"?

Parte 3 — Comunicar

Explica en **3-4 frases, para un CEO no técnico**, qué es la tasa de conversión que calculaste y **una salvedad** de los datos que debería conocer.

Bonus (opcional)

- ¿Hay **personas duplicadas**? ¿Cómo lo resolverías a escala?
-

Entrega: un repositorio (o zip) con el código, el README y tus respuestas a las Partes 2 y 3.